



Universidad Internacional de la Rioja (UNIR)
**Escuela Superior de Ingeniería y
Tecnología**
Máster en Inteligencia Artificial

**Plataforma inteligente para
la recomendación personali-
zada de contenidos en edu-
cación financiera basada en
IA**

Trabajo Fin de Estudios

Tipo de trabajo: Desarrollo de software

Presentado por:

María Verónica Rodríguez Millán

Joaquín Leandro Ramírez Huamán

Dirigido por: Felipe Miron Pozo

Ciudad: Lima, Perú / Mérida, México

Fecha: 21 de abril de 2026

Índice de Contenidos

Resumen	VI
Abstract	VII
1. Introducción	1
1.1. Motivación	1
1.1.1. Identificación del problema	1
1.1.2. Causas del problema	2
1.1.3. Relevancia del problema	3
1.2. Planteamiento del trabajo	4
1.2.1. La necesidad detectada	4
1.2.2. Qué se propone	5
1.2.3. Finalidad de la intervención	5
1.3. Estructura del trabajo	6
2. Contexto y Estado del Arte	8
2.1. Alfabetización Financiera: Definición, Medición y Brechas	8
2.1.1. Definición y marco conceptual	8
2.1.2. Medición estandarizada: Las “Big Three”	8
2.1.3. Brechas específicas en jóvenes profesionales (22–30 años)	9
2.2. Sistemas de Recomendación: Del Filtrado Colaborativo al Deep Learning	10
2.2.1. Fundamentos de los Sistemas de Recomendación (RecSys)	10
2.2.2. Neural Collaborative Filtering (NCF): El salto al Deep Learning	11
2.2.3. Knowledge Graphs en sistemas de recomendación	13
2.3. Machine Learning para Personalización del Aprendizaje	15

2.3.1.	Educational Recommender Systems (ERS)	15
2.3.2.	NLP para la categorización de contenido educativo	15
2.4.	Estado del arte en RecSys aplicados a educación financiera	15
2.4.1.	Sistemas basados en grafos de conocimiento y deep learning	16
2.4.2.	Sistemas tutoriales inteligentes multiagente	16
2.4.3.	Aprendizaje automático para la predicción de alfabetización financiera	16
2.4.4.	Algoritmos de targeting con aprendizaje automático	17
2.4.5.	Sistemas recomendadores educativos con grafos de conocimiento	17
2.4.6.	Comparativa de trabajos relacionados	17
2.4.7.	Vacío identificado	18
2.5.	Selección de arquitectura y justificación del stack tecnológico	19
2.6.	Selección de arquitectura y justificación del stack tecnológico	19
2.6.1.	Modelo de recomendación: NeuMF	19
2.6.2.	Grafo de conocimiento: Neo4j	20
2.6.3.	Motor de IA y backend	21
2.6.4.	Integración KG-RecSys: estrategia de post-filtro	22
2.7.	Conclusiones del estado del arte	22
3.	Objetivos y metodología de trabajo	24
3.1.	Objetivos del trabajo	24
4.	Identificación de Requisitos	25
4.1.	Introducción	25
4.2.	Identificación del problema	25
4.3.	Usuario objetivo	25
4.4.	Contexto de uso	26

4.5. Requisitos funcionales	26
4.6. Requisitos no funcionales	26
4.7. Requisitos de datos	27
4.8. Requisitos pedagógicos	27
4.9. Requisitos de seguridad financiera	28
4.10. Requisitos del sistema de recomendación	28
4.11. Requisitos del grafo de conocimiento	28
4.12. Conclusiones del capítulo	29
 5. Descripción de la herramienta	
software desarrollada	30
5.1. Descripción	30
5.1.1. Objetivo de la herramienta	30
5.1.2. Proceso de desarrollo	30
5.1.3. Arquitectura general	31
5.1.4. Componentes principales	32
5.1.5. Tecnologías utilizadas	32
5.1.6. Funcionamiento de la aplicación	32
5.1.7. Pantallas principales	33
5.1.8. Integración de los componentes	34
5.1.9. Resultado obtenido	34
5.1.10. Conclusión	34
 6. Conclusiones y Trabajo Futuro	35
Referencias	35
 A. Apendices	38

Índice de Ilustraciones

2.1. Uso de un grafo de conocimiento como post-filtro en un sistema de reco-	
mendación educativo	14
6.1. Logo Unir	35

Índice de Tablas

2.1. Comparativa de trabajos relacionados en RecSys aplicados a educación financiera y sistemas educativos con grafos de conocimiento	18
4.1. Perfil del usuario objetivo	26
5.1. Fases del proceso de desarrollo	31
5.2. Tecnologías utilizadas en el prototipo	32
6.1. Tabla 1	35

Resumen

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

LO ESTAMOS DEJANDO PARA EL FINAL

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en español

Abstract

Nota: En este apartado se introducirá un breve resumen en español del trabajo realizado (extensión máxima: 150 palabras). Este resumen debe incluir el objetivo o propósito de la investigación, la metodología, los resultados y las conclusiones.

LO ESTAMOS DEJANDO PARA EL FINAL

Palabras Clave: Se deben incluir de 3 a 5 palabras claves en inglés

María Verónica Rodríguez Millán
Joaquín Leandro Ramírez Huamán
Máster en Inteligencia Artificial

1. Introducción

1.1. Motivación

1.1.1. Identificación del problema

El problema central de este trabajo es la existencia de una brecha crítica entre la capacidad de ahorro de los jóvenes profesionales españoles (18–34 años) y su nivel de alfabetización financiera.

A pesar de encontrarse en una etapa vital determinante —caracterizada por la incorporación al mercado laboral y la formación del hogar—, este colectivo presenta dificultades para transformar el ahorro acumulado en una planificación financiera eficiente. Esta situación refleja una desconexión entre la capacidad de ahorro y la capacidad de gestión financiera efectiva, limitando la generación de patrimonio y estabilidad económica futura.

Según los resultados de la [Encuesta de Competencias Financieras \(ECF\)](#) 2021 del Banco de España, los individuos de entre 18 y 34 años han mejorado su nivel promedio de conocimientos financieros, pasando de un 46 % de respuestas correctas en 2016 a un 52 % en 2021. No obstante, este avance continúa mostrando carencias significativas en conceptos financieros fundamentales.

En particular, únicamente el 44 % de los jóvenes respondió correctamente a la pregunta relacionada con el interés compuesto, porcentaje inferior al obtenido en conceptos como inflación (60 %) o diversificación del riesgo (50 %). Esta situación evidencia dificultades en la comprensión del crecimiento acumulativo del capital y de los efectos que la inflación puede generar sobre el valor real del ahorro a largo plazo. ([Hospido, Machelett, Pidkuyko, y Villanueva, 2023](#))

Esta carencia de conocimientos financieros no es únicamente teórica, sino que también se refleja en los hábitos de ahorro y en la utilización de instrumentos financieros por parte de la población joven. Según la Encuesta de Competencias Financieras (ECF) 2021 del Banco de España, el 87 % de los individuos entre 18 y 34 años afirma haber ahorrado durante los últimos doce meses, situándose como el grupo con mayor propensión al ahorro. Sin embargo, gran parte de este ahorro se concentra en mecanismos de baja rentabilidad y escasa protección frente a la inflación.

Entre los jóvenes que han ahorrado, el 67 % utiliza cuentas corrientes como principal medio de ahorro y el 60 % conserva dinero en efectivo fuera del sistema financiero. En contraste, únicamente un 6 % declara utilizar fondos de inversión y un 3 % planes de pensiones como instrumentos de ahorro. Estos resultados evidencian una preferencia por formas de ahorro de elevada liquidez, pero con limitada capacidad de generación de rentabilidad real a largo plazo.

Finalmente, los enfoques tradicionales de educación financiera se enfrentan a un entorno de complejidad creciente. Los jóvenes profesionales hoy operan en una economía digitalizada y a menudo se enfrentan a la inestabilidad de ingresos propia de la economía de plataforma o contratos temporales, lo que requiere una capacidad de planificación y resiliencia mucho mayor que en décadas anteriores. Los modelos de formación estáticos y generales han demostrado ser insuficientes, ya que no logran personalizar el aprendizaje según el comportamiento real del usuario ni mitigar los nuevos riesgos digitales, como la promoción de productos financieros complejos mediante dinámicas digitales altamente interactivas o los fraudes en entornos en línea.

La creciente digitalización de este grupo poblacional ofrece una oportunidad significativa para abordar esta problemática desde una perspectiva tecnológica. Los jóvenes presentan una alta interacción con entornos digitales, lo que genera una mayor disponibilidad de datos comportamentales y de consumo, facilitando el desarrollo de soluciones más precisas y adaptativas.

En este contexto, la inteligencia artificial y los sistemas de recomendación permiten desarrollar plataformas capaces de analizar patrones de comportamiento financiero y adaptar dinámicamente los contenidos educativos según las características y necesidades del usuario. De este modo, se propone el desarrollo de una plataforma inteligente de recomendación de contenidos en educación financiera basada en IA, orientada a mejorar la toma de decisiones y fomentar una gestión activa y eficiente de los recursos económicos en los jóvenes profesionales.

1.1.2. Causas del problema

Las causas de esta situación son multidimensionales y pueden categorizarse en tres ejes:

1. **Falta de educación formal adaptada:** El sistema educativo tradicional en España no integra de manera transversal la educación financiera en los planes de estudio.

Cuando esta formación existe, suele ser predominantemente teórica y escasamente vinculada a la realidad digital actual, caracterizada por el uso de aplicaciones de inversión, plataformas fintech y nuevos instrumentos financieros digitales.

2. **Sesgos cognitivos y psicológicos:** Los jóvenes profesionales están expuestos a diversos sesgos conductuales que afectan su toma de decisiones financieras. Entre ellos destacan el overconfidence bias (exceso de confianza en sus propios conocimientos) y el present bias (preferencia por recompensas inmediatas frente a beneficios futuros), lo que conduce a priorizar el consumo o el ahorro a corto plazo en detrimento de estrategias de inversión a largo plazo.
3. **Complejidad y “ruido” digital:** La digitalización ha generado una sobreabundancia de información y un acceso masivo a productos financieros complejos, como criptoactivos o servicios de financiación inmediata (BNPL). La ausencia de herramientas de filtrado y personalización provoca que los jóvenes se enfrenten a un entorno informativo saturado, lo que puede derivar en decisiones basadas en fuentes no especializadas o tendencias de redes sociales, en lugar de criterios técnicos fundamentados.

1.1.3. Relevancia del problema

Este problema es de vital importancia tanto para la comunidad científica como para la sociedad por las siguientes razones:

- **Impacto en la estabilidad económica:** La dificultad para superar la denominada “barrera del ahorro inicial” limita el acceso a activos clave como la vivienda. Esta barrera se estima en torno al 30–32 % del valor del inmueble, considerando aproximadamente un 20 % de entrada no financiada por entidades bancarias y un 10–12 % adicional correspondiente a impuestos y gastos asociados. Esta situación retrasa hitos vitales fundamentales y reduce la capacidad de generación de riqueza a largo plazo en los jóvenes profesionales.
- **Vulnerabilidad ante fraudes:** La insuficiente alfabetización financiera, especialmente en entornos digitales, incrementa la exposición a ciberestafas, productos financieros de alto riesgo y decisiones de inversión mal fundamentadas. En un contexto de creciente digitalización, esta vulnerabilidad representa un riesgo significativo para la estabilidad económica individual.

- **Relevancia para la investigación y la innovación educativa:** Desde el ámbito académico, existe una creciente necesidad de explorar nuevas metodologías que mejoren la educación financiera. En este sentido, la inteligencia artificial se presenta como una herramienta clave para transformar los modelos tradicionales, permitiendo el desarrollo de sistemas adaptativos capaces de personalizar el aprendizaje en función del perfil, comportamiento y necesidades específicas de cada usuario. En conjunto, estos factores evidencian la necesidad de desarrollar soluciones innovadoras que no solo aborden la falta de conocimientos financieros, sino que también faciliten su aplicación práctica mediante enfoques personalizados y basados en datos, como los que permite la inteligencia artificial.

1.2. Planteamiento del trabajo

1.2.1. La necesidad detectada

El problema identificado no se limita únicamente a la falta de educación financiera, sino también a la ausencia de mecanismos de personalización en la distribución de contenidos educativos. Los sistemas actuales de educación financiera —tanto aplicaciones de fintech como plataformas de *e-learning*— operan con lógicas de recomendación rudimentarias: filtros por categorías manuales, listados estáticos de “cursos populares” o, en el mejor de los casos, algoritmos clásicos de recomendación basados en filtrado colaborativo que no consideran las relaciones de dependencia y progresión existentes entre los distintos conceptos financieros.

Desde la perspectiva de la Inteligencia Artificial, esto presenta tres deficiencias técnicas:

1. **Limitaciones asociadas al problema de “Cold Start” pedagógico:** Cuando un usuario nuevo accede al sistema, no existe un historial previo de interacción del usuario con la plataforma. Los sistemas tradicionales no pueden recomendar nada relevante. Un modelo de IA debe poder inferir un perfil inicial a partir de datos demográficos y una evaluación diagnóstica.
2. **Falta de modelado del conocimiento:** Las finanzas personales no son un conjunto de temas independientes. Existen relaciones de prerrequisito estrictas (ej. no se puede entender “fondos indexados” sin dominar “diversificación” e “interés compuesto”). Los sistemas actuales no modelan adecuadamente estas relaciones de dependencia

entre conceptos financieros.

3. **Ausencia de aprendizaje secuencial:** La educación es un proceso temporal. Un sistema de IA debe optimizar no la relevancia de una única recomendación, sino una secuencia progresiva de contenidos educativos adaptados al nivel del usuario que favorezca una mejor asimilación progresiva del conocimiento financiero.

Con ello, se busca mejorar la experiencia de aprendizaje financiero mediante recomendaciones más relevantes, adaptativas y alineadas con las necesidades reales de cada usuario.

1.2.2. Qué se propone

Ante estas limitaciones, se propone el desarrollo de una plataforma inteligente de educación financiera personalizada, basada en la integración de técnicas de aprendizaje profundo y grafos de conocimiento. El núcleo del sistema combinará un modelo híbrido de recomendación (NeuMF) capaz de aprender patrones complejos de interacción usuario-contenido, con un grafo de conocimiento que modele las dependencias pedagógicas entre conceptos financieros. De este modo, las recomendaciones serán simultáneamente personalizadas al perfil del usuario y coherentes con la progresión lógica del aprendizaje.

La materialización de la propuesta se concretará en un prototipo web funcional que permita validar la viabilidad técnica y pedagógica del enfoque. El usuario completará un cuestionario inicial de perfilado, recibirá un itinerario de aprendizaje adaptado y avanzará mediante módulos con evaluaciones formativas que retroalimenten al modelo.

La justificación detallada de esta arquitectura, así como el análisis comparativo frente a otras alternativas existentes en la literatura, se presenta en el capítulo 2 (Contexto y Estado del Arte). El capítulo 3 describe la metodología completa, el capítulo 4 la implementación y resultados experimentales, y el capítulo 5 las conclusiones y líneas futuras.

1.2.3. Finalidad de la intervención

La finalidad es doble:

1. **Científica:** Evaluar el impacto de la integración de Knowledge Graphs con arquitecturas de Neural Collaborative Filtering sobre métricas de recomendación (NDCG@k, Precision@k) y sobre la coherencia pedagógica del itinerario formativo.
2. **Aplicada:** Entregar un prototipo funcional validado que sirva como prueba de concepto para una plataforma de educación financiera personalizada, demostrando el

potencial de la IA para proporcionar experiencias de aprendizaje financiero más personalizadas y adaptativas.

1.3. Estructura del trabajo

Para abordar el problema y la propuesta descritos en los apartados anteriores, la memoria se organiza en cinco capítulos, siguiendo una progresión lógica que va desde la identificación del problema hasta la validación empírica del prototipo:

- **Capítulo 1: Introducción.** Este capítulo establece las bases del trabajo. Se identifica el problema de la brecha de alfabetización financiera en jóvenes profesionales españoles, se justifica su relevancia desde las perspectivas social y tecnológica, y se plantea la propuesta de un sistema de recomendación basado en aprendizaje profundo como solución. Finalmente, se definen los objetivos generales y específicos que guiarán el desarrollo del proyecto.
- **Capítulo 2: Contexto y Estado del Arte.** Se revisa la literatura científica fundamental para contextualizar el trabajo. Se analizan tres bloques temáticos: (i) los fundamentos de la alfabetización financiera y las brechas detectadas en la población objetivo; (ii) los sistemas de recomendación tradicionales y sus limitaciones en entornos educativos; y (iii) las arquitecturas de *Neural Collaborative Filtering* y el uso de *Knowledge Graphs* como vías para superar dichas limitaciones.
- **Capítulo 3: Objetivos concretos y metodología de trabajo.** Describe la arquitectura completa del sistema propuesto. Se detalla el pipeline de datos: obtención y preprocesamiento de datasets (ECF 2021, metadatos de cursos), diseño del modelo NeuMF, construcción del grafo de conocimiento financiero, y la estrategia de integración entre ambos componentes.
- **Capítulo 4: Identificación de Requisitos.** Este capítulo presenta el trabajo previo realizado para orientar el desarrollo del software. Se identifica el problema a tratar, el perfil de usuario objetivo y el contexto habitual de uso de la aplicación. Asimismo, se definen los requisitos funcionales, no funcionales, pedagógicos, de datos y de seguridad financiera que debe cumplir el prototipo. Esta fase permite establecer una base clara para el diseño posterior del sistema de recomendación y del grafo de conocimiento.
- **Capítulo 5: Descripción de la Herramienta Software Desarrollada.** Este

capítulo describe el prototipo software desarrollado como resultado del trabajo. Se documentan las fases principales del proceso de desarrollo, los hitos alcanzados, el stack tecnológico utilizado y la arquitectura general de la aplicación. También se presentan diagramas explicativos del funcionamiento del sistema, el flujo de interacción del usuario y capturas de pantalla que permiten comprender el comportamiento del programa. El prototipo integra una aplicación web, una API desarrollada con FastAPI, un modelo de recomendación, un grafo de conocimiento y una interfaz de usuario para la recomendación personalizada de contenidos educativos.

- **Capítulo 6: Conclusiones y Líneas Futuras.** Se sintetizan los logros alcanzados en relación con los objetivos planteados, se reflexiona sobre las limitaciones del sistema desarrollado y se proponen vías de mejora y escalabilidad.

Adicionalmente, la memoria incluye una sección de Referencias Bibliográficas que recoge las fuentes académicas, técnicas e institucionales citadas a lo largo del documento. Asimismo, se incorporan anexos con material complementario del proyecto, incluyendo el enlace al repositorio donde se aloja el código fuente, los datos utilizados y los recursos necesarios para reproducir el prototipo.

2. Contexto y Estado del Arte

2.1. Alfabetización Financiera: Definición, Medición y Brechas

2.1.1. Definición y marco conceptual

La alfabetización financiera ha evolucionado desde un concepto meramente informativo hacia una competencia multidimensional. La definición más ampliamente aceptada en la literatura económica es la propuesta por Lusardi y Mitchell (Lusardi y Mitchell, 2014), quienes la conciben como el conocimiento de los conceptos financieros básicos necesarios para tomar decisiones económicas informadas.

La OCDE/INFE, en la *International Survey of Adult Financial Literacy*, propone un modelo de tres dimensiones para operacionalizar la medición de la alfabetización financiera: conocimientos financieros, comportamiento financiero y actitud financiera (Organisation for Economic Co-operation and Development, 2023).

1. **Conocimientos financieros (*Financial Knowledge*):** Comprensión de conceptos clave como inflación, interés compuesto, diversificación y relación riesgo-rentabilidad.
2. **Comportamiento financiero (*Financial Behaviour*):** Prácticas concretas de gestión del dinero (presupuestación, ahorro regular, planificación de jubilación).
3. **Actitud financiera (*Financial Attitude*):** Disposición psicológica hacia el largo plazo frente al corto plazo, la propensión al riesgo y la dependencia del endeudamiento.

Este marco tripartito resulta especialmente relevante para el presente trabajo porque permite identificar que un usuario puede tener conocimientos teóricos pero un comportamiento subóptimo, lo cual refuerza la necesidad de un sistema que no solo enseñe, sino que modele y acompañe la conducta.

2.1.2. Medición estandarizada: Las “Big Three”

El instrumento de medición más difundido internacionalmente son las denominadas *Big Three questions*, desarrolladas por Lusardi y Mitchell y adoptadas por la OCDE, el Banco

de España y otras instituciones. Las preguntas evalúan:

- **Interés compuesto:** Si tienes 100€ a un interés del 2 % anual, ¿cuánto tendrás al cabo de 5 años?
- **Inflación:** Si la tasa de interés de una cuenta de ahorro es del 1 % anual y la inflación del 2 %, ¿puedes comprar más, lo mismo o menos dentro de un año?
- **Diversificación:** ¿Es cierto que una cartera de inversión con un solo activo es generalmente menos riesgosa que una cartera con múltiples activos?

Los resultados de la ECF 2021 (Hospido y cols., 2023) en España revelan patrones críticos para el segmento objetivo de este TFM:

- Solo el 46 % de la población adulta responde correctamente a las tres preguntas.
- En el tramo de 18–34 años, el porcentaje desciende al 17 %, con una brecha significativa entre hombres y mujeres.
- El 83 % de los jóvenes españoles acierta en la pregunta de inflación, pero el rendimiento cae drásticamente en interés compuesto (47 %) y diversificación (49 %).

2.1.3. Brechas específicas en jóvenes profesionales (22–30 años)

El colectivo de jóvenes profesionales presenta características diferenciales que justifican un tratamiento específico respecto a otros segmentos etarios.

a) Paradoja del ahorro pasivo

A pesar de ser el grupo con mayor propensión al ahorro, la gestión del ahorro es marcadamente pasiva. Los jóvenes profesionales concentran sus activos líquidos en productos de bajo riesgo y nula rentabilidad real, mientras que la inversión en productos de renta variable o planes de pensiones es marginal.

b) Brecha de vivienda y “trampa del alquiler”

El acceso a la vivienda constituye el principal objetivo de ahorro de los jóvenes profesionales españoles. Sin embargo, la conjunción de precios de vivienda elevados, salarios de entrada contenidos y la exigencia de un ahorro inicial del 32 % convierte este hito en inalcanzable para la mayoría.

c) Digitalización sin criterio: criptoactivos y fintech

El acceso facilitado por aplicaciones móviles ha democratizado la inversión, pero no la educación sobre riesgos asociados. Esto incrementa la exposición a decisiones financieras mal informadas.

d) Sesgos cognitivos

La literatura de economía conductual identifica sesgos particularmente prevalentes en este grupo:

- **Sobreconfianza:** Tendencia a sobrestimar la propia capacidad de predicción y conocimiento financiero, lo que conduce a subestimar riesgos y descartar formación introductoria percibida como innecesaria.
- **Sesgo de presente:** Preferencia desproporcionada por recompensas inmediatas frente a mayores beneficios futuros, manifestada en la concentración del ahorro en instrumentos líquidos de baja rentabilidad real.
- **Efecto de anclaje:** dependencia excesiva de la primera información recibida (precio de referencia, opinión inicial o dato visto en redes sociales) al formular juicios y decisiones posteriores.

2.2. Sistemas de Recomendación: Del Filtrado Colaborativo al Deep Learning

2.2.1. Fundamentos de los Sistemas de Recomendación (RecSys)

Los sistemas de recomendación son herramientas de software que predicen la utilidad o preferencia que un usuario tendrá por un ítem no visto, basándose en datos históricos de interacciones usuario-ítem. Su objetivo es mitigar la sobrecarga de información presentando al usuario un subconjunto filtrado de ítems potencialmente relevantes (Zhang, Yao, Sun, y Tay, 2019).

Tradicionalmente, los RecSys se clasifican en tres paradigmas:

1. **Filtrado Colaborativo (CF):** El CF infiere las preferencias de un usuario a partir de la similitud con otros usuarios (user-based) o de la similitud entre ítems (item-based). La técnica más representativa es la factorización matricial (Matrix Factorization, MF), que descompone la matriz de interacciones usuario-ítem en dos matrices

de embeddings de menor dimensión. Aunque eficaz en escenarios con abundantes datos de interacción, el CF puro presenta dos limitaciones críticas en el contexto de este trabajo: el problema del cold start (usuarios nuevos sin historial de interacción con la plataforma) y la incapacidad para incorporar atributos contextuales del usuario (edad, nivel de ingresos, perfil de riesgo) que son fundamentales para personalizar contenidos de educación financiera, limitaciones ampliamente documentadas en la literatura de sistemas de recomendación (Zhang y cols., 2019).

2. **Filtrado Basado en Contenido (CB):** El CB recomienda ítems similares a aquellos que el usuario ha consumido previamente, basándose en la similitud de atributos entre usuarios e ítems. En el ámbito educativo, esto traduce a recomendar contenidos cuya dificultad, formato o temática se alineen con el perfil del estudiante. Su principal ventaja es que no requiere datos de otros usuarios, mitigando parcialmente el cold start. Sin embargo, su limitación más severa es la overspecialization: al recomendar siempre contenidos similares a los ya consumidos, el sistema ignora patrones colectivos de aprendizaje y dificulta la descubribilidad de nuevos temas necesarios para una formación completa. En educación financiera, esto equivaldría a encasillar al usuario en su zona de confort (presupuesto y ahorro) sin impulsarle hacia conceptos más avanzados (inversión, jubilación).
3. **Métodos Híbridos:** Los métodos híbridos combinan CF y CB para superar las limitaciones individuales de cada paradigma, reduciendo problemas como el cold start y la overspecialization (Zhang y cols., 2019). En escenarios educativos, los híbridos permiten aprovechar tanto los patrones colectivos de aprendizaje como las características individuales del estudiante. No obstante, las arquitecturas híbridas clásicas (por ejemplo, factorización matricial con side information) siguen estando limitadas por la naturaleza lineal de sus funciones de interacción, lo que dificulta captar relaciones complejas entre múltiples variables contextuales.

2.2.2. Neural Collaborative Filtering (NCF): El salto al Deep Learning

El trabajo seminal de He et al. (He y cols., 2017a) representa un punto de inflexión en los RecSys. Los autores proponen el *Neural Collaborative Filtering (NCF)*, un marco que sustituye el producto escalar lineal de la factorización matricial por una red neuronal multicapa capaz de aprender funciones de interacción arbitrarias.

La arquitectura NCF se compone de dos representaciones fundamentales que pueden combinarse de forma modular:

- **GMF (Generalized Matrix Factorization):** Extiende la factorización matricial tradicional permitiendo un producto elemento a elemento aprendido (*element-wise product*) entre los embeddings de usuario e ítem, seguido de una activación lineal con peso aprendible. Esta componente preserva la capacidad del CF clásico para capturar patrones globales de interacción usuario-contenido, es decir, tendencias colectivas del tipo “^a usuarios con perfil similar le resultó útil este contenido”.
- **MLP (Multi-Layer Perceptron):** Concatena los embeddings de usuario e ítem y los procesa a través de capas densas con activaciones no lineales (ReLU, habitualmente). El MLP aprende relaciones complejas a partir de variables contextuales: edad, nivel de ingresos, propensión al ahorro, conocimientos previos del usuario, así como dificultad, formato o temática del contenido educativo. Esta componente es la que permite al modelo personalizar la recomendación a perfiles heterogéneos, como los jóvenes profesionales españoles con niveles dispares de alfabetización financiera.

La arquitectura **NeuMF** (Neural Matrix Factorization) surge de la concatenación de las salidas de GMF y MLP en una capa de predicción final:

$$\hat{y}_{ui} = \sigma(h^T[\phi^{GMF}(p_u \odot q_i), \phi^{MLP}(p_u, q_i)]) \quad (2.1)$$

Donde p_u y q_i son los embeddings de usuario e ítem, ϕ_{GMF} y ϕ_{MLP} son las funciones de transformación de cada componente, h^T es el vector de pesos de la capa de salida y σ la función de activación (típicamente sigmoide para predicción de probabilidad de interacción).

Justificación de NeuMF para educación financiera. NeuMF clásico (He y cols., 2017b) modela únicamente interacciones entre embeddings de usuario e ítem, combinando patrones globales (GMF) con relaciones no lineales aprendidas por el MLP. Sin embargo, en este dominio la utilidad pedagógica de un contenido depende también de características contextuales del usuario: edad, nivel de ingresos, conocimientos previos o perfil de riesgo. Para incorporar estas variables, se propone una variante **feature-aware NeuMF** que enriquece el vector de entrada del MLP con características demográficas y diagnósticas del usuario además de sus embeddings. Esta extensión, común en la literatura de sistemas de

recomendación híbridos, permite mitigar el **cold start** pedagógico: incluso para un usuario sin historial de interacción en la plataforma, el modelo puede inferir un perfil inicial a partir de sus respuestas al cuestionario de perfilado. Así, la arquitectura base (NeuMF) captura patrones de interacción usuario-contenido, mientras que el enriquecimiento con variables contextuales habilita la personalización a perfiles heterogéneos.

2.2.3. Knowledge Graphs en sistemas de recomendación

Los Grafos de Conocimiento (KG) son estructuras de datos que representan entidades y sus relaciones semánticas mediante nodos y aristas. En el ámbito de los RecSys, los KG aportan información estructurada que los modelos tradicionales no capturan, constituyendo una de las líneas más relevantes en la evolución reciente de los sistemas de recomendación (Guo y cols., 2020).

Existen tres formas principales de integrar KG en recomendadores, especialmente en arquitecturas híbridas basadas en Deep Learning (Gao, Li, Lin, Gao, y Khan, 2020), con distintos niveles de acoplamiento con el modelo de predicción:

1. **KG como restricción (post-filtro o pre-filtro):** El modelo de recomendación genera un ranking de candidatos y el grafo filtra aquellos que violan restricciones semánticas. En educación, esto traduce a descartar contenidos cuyos prerrequisitos conceptuales no hayan sido dominados por el estudiante. Su ventaja es el desacoplamiento total entre el entrenamiento del modelo neuronal y la evolución del grafo: el catálogo de contenidos puede crecer o modificarse sin reentrenar la red. Su riesgo es la escasez de candidatos: si el modelo ignora sistemáticamente la estructura pedagógica, el filtrado puede dejar al usuario con muy pocas recomendaciones válidas.
2. **KG como enriquecimiento de embeddings:** Los embeddings del grafo (obtenidos mediante técnicas como Node2Vec, DeepWalk o Graph Neural Networks) se inyectan como vectores adicionales de entrada en el modelo de recomendación. De este modo, el modelo aprende implícitamente a respetar la estructura del grafo durante el entrenamiento. Su ventaja es que las restricciones pedagógicas se incorporan en la función de predicción, reduciendo la probabilidad de generar candidatos inválidos. Su desventaja es el acoplamiento: cualquier cambio en el grafo requiere reentrenar o ajustar el modelo.
3. **KG como camino de explicación:** El grafo se utiliza para generar rutas de razo-

namiento que expliquen por qué se recomienda un ítem (por ejemplo: "se recomienda 'Fondos indexados' porque el usuario dominó 'Diversificación', que es prerequisite de 'Inversión', que a su vez habilita 'Fondos indexados'"). Esta estrategia mejora la transparencia del sistema y fomenta la confianza del usuario, aspecto especialmente relevante en educación financiera donde la comprensión del "porqué" refuerza el aprendizaje.




Figura 2.1: Uso de un grafo de conocimiento como post-filtro en un sistema de recomendación educativo

La Figura 2.1 muestra un ejemplo simplificado del uso de un grafo de conocimiento en un sistema de recomendación educativo. El modelo genera una lista inicial de contenidos candidatos y el grafo actúa como mecanismo de post-filtro, descartando aquellos contenidos cuyos prerequisites conceptuales no han sido dominados por el usuario.

La alfabetización financiera es inherentemente jerárquica: no se puede enseñar "fondos indexados" sin que el usuario domine previamente "diversificación" e "interés compuesto". Ignorar esta estructura genera recomendaciones técnicamente precisas (alto NDCG@k) pero pedagógicamente inútiles. El KG garantiza que el sistema respete el orden de adquisición del conocimiento, funcionando como capa de validación semántica sobre el modelo de recomendación.

2.3. Machine Learning para Personalización del Aprendizaje

2.3.1. Educational Recommender Systems (ERS)

Los sistemas de recomendación educativos constituyen una especialización de los RecSys generalistas, donde el objetivo no es maximizar el clic o el tiempo de consumo, sino el aprendizaje efectivo. Esta línea de investigación ha experimentado un crecimiento significativo en los últimos años debido al avance de técnicas de Machine Learning aplicadas a la personalización educativa (Khanal, Prasad, Alsadoon, y Maag, 2020).

Esto introduce métricas de evaluación específicas:

- **Mastery Learning**
- **Retención a largo plazo**
- **Engagement educativo**

2.3.2. NLP para la categorización de contenido educativo

El catálogo de contenido financiero disponible carece de una taxonomía unificada. El Procesamiento de Lenguaje Natural (NLP) permite:

- **Extracción automática de tópicos**
- **Vectorización semántica**

Para este TFM, el NLP actuará como puente entre el contenido crudo y el espacio vectorial del modelo de recomendación.

2.4. Estado del arte en RecSys aplicados a educación financiera

La aplicación de sistemas de recomendación al ámbito de la educación financiera es un campo incipiente, pero de creciente interés. A continuación se analizan los trabajos más relevantes identificados en la literatura, ordenados según su cercanía técnica con la propuesta del presente trabajo.

2.4.1. Sistemas basados en grafos de conocimiento y deep learning

El trabajo más directamente comparable es el de Verma et al. (Verma y cols., 2023), quienes desarrollaron un sistema de recomendación de artículos educativos financieros para una multinacional de servicios financieros. Los autores combinan un *knowledge graph* generado automáticamente a partir de datos estructurados, como demografía de suscriptores, temas y productos, y datos no estructurados, como el texto completo de artículos educativos.

Sobre esta representación, proponen un recomendador basado en *reinforcement learning* que recorre el grafo para encontrar rutas de recomendación explicables. Los autores reportan un MAP@10 del 43,76 %, superando a baselines de filtrado colaborativo, como *Bayesian Personalized Ranking* (BPR), y *Neural Collaborative Filtering* (NCF).

No obstante, su sistema no modela dependencias pedagógicas entre conceptos ni incorpora un mecanismo de evaluación de maestría. Su objetivo principal es maximizar la lectura de artículos, no garantizar una progresión didáctica.

2.4.2. Sistemas tutoriales inteligentes multiagente

Marín y Notargiacomo (Marín y Notargiacomo, 2021) proponen *Stima*, un sistema tutorial inteligente multiagente para educación financiera. El sistema adquiere conocimiento de expertos y utiliza análisis sintáctico, léxico y semántico para definir perfiles financieros de los estudiantes y recomendar estándares de planificación financiera personalizada.

Aunque este trabajo aborda el perfilado del usuario, su arquitectura se basa en reglas y agentes conversacionales. Por tanto, no utiliza *deep learning* ni modela secuencias de aprendizaje mediante estructuras de grafo.

2.4.3. Aprendizaje automático para la predicción de alfabetización financiera

Zhu (Zhu, 2024) propone un marco de *machine learning* supervisado para predecir niveles de alfabetización financiera en población joven a partir de datos sociodemográficos y conductuales. El autor entrena y compara distintos algoritmos, como árbol de decisión, *Random Forest*, *LightGBM* y *SVM*, sobre datos de encuesta.

El trabajo también aplica análisis de ablación para identificar las características más predictivas, entre ellas edad, nivel educativo, ingresos y experiencia previa con productos financieros. Aunque no construye un sistema de recomendación de contenidos, demuestra

la viabilidad del *machine learning* para el perfilado automático de usuarios en el dominio financiero. Esta capacidad es relevante para mitigar el problema de *cold start* en sistemas recomendadores educativos.

2.4.4. Algoritmos de targeting con aprendizaje automático

D’Ignazio y Buratti (D’Ignazio y Buratti, 2023) emplean técnicas de *machine learning* para identificar, a partir de características observables, qué individuos podrían beneficiarse más de programas de educación financiera.

Su aporte se centra en la personalización de la entrega de la formación, no en la personalización del contenido educativo. En consecuencia, el trabajo no aborda la recomendación de materiales, la secuenciación pedagógica ni la adaptación progresiva del aprendizaje.

2.4.5. Sistemas recomendadores educativos con grafos de conocimiento

Fuera del ámbito financiero, existe una línea de investigación activa sobre grafos de conocimiento aplicados a sistemas de recomendación educativos. Hua et al. (Hua, Yang, y Ji, 2025) proponen KGCN-UP, un modelo basado en *Knowledge Graph Convolutional Networks* con preferencias de usuario para la recomendación de cursos MOOC. Este enfoque aborda, entre otros aspectos, el problema de la escasez de datos.

De forma similar, Duan et al. (Duan y cols., 2025) presentan LKGA, una red de atención sobre grafos de conocimiento orientada a mejorar la recomendación de recursos de aprendizaje en sistemas de tutoría inteligente.

Estos trabajos demuestran la viabilidad técnica de integrar grafos de conocimiento con modelos neuronales en contextos educativos. Sin embargo, no abordan la especificidad del dominio financiero ni el público de jóvenes profesionales.

2.4.6. Comparativa de trabajos relacionados

En la Tabla 2.1 se resume la comparativa técnica entre los trabajos revisados y la propuesta del presente TFM.

Tabla 2.1: Comparativa de trabajos relacionados en RecSys aplicados a educación financiera y sistemas educativos con grafos de conocimiento

Trabajo	Dominio	Modelo	KG	Cold start	Secuenciación pedagógica
Verma et al. (2023)	Artículos financieros educativos	RL + KG	Sí	Limitado	No
Marín y Notargiacomo (2021)	Planificación financiera	Reglas multiagente	No	Perfilado manual	No
Zhu (2024)	Alfabetización financiera en jóvenes	ML supervisado: RF, LightGBM, SVM	No	Con datos de encuesta	No
D'Ignazio y Burratti (2023)	Educación financiera: <i>targeting</i>	ML clásico	No	No aplica	No
Hua et al. (2025)	Cursos MOOC	KGCN-UP	Sí	Parcial	No
Duan et al. (2025)	Tutoría inteligente	LKGA: KG + atención	Sí	Parcial	No
Propuesta	Educación financiera en jóvenes	Feature-aware NeuMF + KG	Sí	Sí, mediante cuestionario diagnóstico	Sí, mediante grafo de prerrequisitos

2.4.7. Vacío identificado

Ninguno de los trabajos revisados combina *Neural Collaborative Filtering* ~~con grafos~~ con grafos de conocimiento en el dominio específico de la educación financiera para jóvenes, integrando simultáneamente tres elementos: personalización de contenido mediante un modelo híbrido de *deep learning*, restricciones pedagógicas de secuenciación modeladas explícitamente mediante un grafo de conocimiento y un mecanismo de evaluación de maestría que retroalimente el sistema.

Este vacío constituye la contribución científica principal del presente trabajo. La propuesta plantea un sistema basado en *feature-aware NeuMF* combinado con un grafo de conoci-

miento que actúa como mecanismo de control pedagógico, evitando recomendaciones que no respeten los prerrequisitos conceptuales del usuario.

2.5. Selección de arquitectura y justificación del stack tecnológico

Tras el análisis del estado del arte, se procede a justificar la arquitectura y el stack tecnológico seleccionados para el prototipo. La propuesta se basa en la integración de un modelo de recomendación, un grafo de conocimiento y una aplicación web conectada mediante API, en línea con el objetivo de desarrollar una prueba de concepto funcional.

~~2.6. Selección de arquitectura y justificación del stack tecnológico~~

2.6.1. Modelo de recomendación: NeuMF

La elección de una arquitectura basada en NeuMF frente a alternativas clásicas, como la factorización matricial o los sistemas basados en contenido, se fundamenta en tres argumentos principales.

En primer lugar, se considera el problema del *cold start* pedagógico. Los usuarios nuevos no tienen historial de interacción con la plataforma, por lo que un sistema puramente colaborativo no puede funcionar adecuadamente desde el primer uso. Para mitigar esta limitación, se propone una variante *feature-aware NeuMF*, que integra características del usuario, como edad, ingresos, conocimientos previos y perfil de riesgo, en el vector de entrada del MLP. Esto permite inferir preferencias iniciales incluso sin historial de interacción.

En segundo lugar, la educación financiera presenta una alta heterogeneidad en los perfiles de usuario. Las finanzas personales dependen de relaciones no lineales entre variables como ingresos, edad, conocimientos previos, hábitos de ahorro y propensión al riesgo. Estas relaciones no son capturadas de forma suficiente por modelos lineales de factorización matricial. En cambio, el componente MLP de NeuMF permite modelar interacciones más complejas entre variables contextuales.

En tercer lugar, la arquitectura GMF+MLP ofrece modularidad. Permite experimentar con distintas configuraciones, como solo GMF, solo MLP, combinación completa o variantes con y sin *features* contextuales. Esta flexibilidad facilita comparar empíricamente qué

configuración funciona mejor en el dominio educativo.

La selección definitiva del modelo no se plantea como una decisión exclusivamente teórica. Se sustentará en una evaluación experimental en la que se medirán métricas estándar de recomendación, como NDCG@k y Precision@k, junto con una métrica específica de coherencia pedagógica. Esta métrica se define como el porcentaje de recomendaciones que respetan las dependencias conceptuales del dominio.

2.6.2. Grafo de conocimiento: Neo4j

Se selecciona Neo4j como base de datos orientada a grafos. Esta elección se justifica por tres motivos: la naturaleza pedagógica del dominio, la comparación frente a bases de datos relacionales y la comparación frente a otras bases de datos de grafos.

Naturaleza del dominio

La educación financiera presenta una estructura conceptual jerárquica. Los conceptos no existen de forma aislada, sino conectados mediante relaciones de prerrequisito, especialización y secuencia. Por ejemplo, antes de estudiar fondos indexados, el usuario debería comprender conceptos como riesgo, diversificación, inflación e interés compuesto.

Modelar estas relaciones en una base de datos relacional requeriría tablas intermedias y consultas recursivas para recuperar todos los prerrequisitos de un contenido. En cambio, en un grafo esta consulta puede resolverse mediante recorridos entre nodos y relaciones, lo que resulta más natural para representar dependencias conceptuales.

Comparativa frente a bases relacionales

En bases de datos relacionales, como PostgreSQL o MySQL, la validación de dependencias pedagógicas implicaría consultas recursivas o uniones sucesivas entre tablas. Esto puede aumentar la complejidad de consulta y dificultar el mantenimiento del modelo cuando crece el número de conceptos y relaciones.

Neo4j almacena las relaciones como parte central del modelo de datos, lo que facilita recorrer conexiones entre conceptos y contenidos. Esto resulta adecuado para validar, antes de mostrar una recomendación, si el usuario ha cubierto los prerrequisitos necesarios.

Comparativa frente a otras bases de grafos

También se consideraron alternativas como ArangoDB, Amazon Neptune y JanusGraph. Sin embargo, se descartaron por las siguientes razones:

- **ArangoDB:** aunque es una base de datos multimodelo y soporta grafos, Neo4j ofrece un ecosistema más consolidado para consultas de grafos y recorridos complejos mediante Cypher.
- **Amazon Neptune:** requiere infraestructura en AWS, lo que incrementa la complejidad de despliegue y puede generar costes recurrentes. Para un prototipo académico, esta dependencia no resulta necesaria.
- **JanusGraph:** está orientada a grafos masivos distribuidos con backends como Cassandra o HBase. Su arquitectura excede las necesidades del presente TFM, donde el grafo de conocimiento financiero será de tamaño moderado.

Factores decisivos a favor de Neo4j

Los factores decisivos para seleccionar Neo4j son los siguientes:

- **Lenguaje Cypher:** permite expresar consultas de grafos de forma declarativa y legible. Por ejemplo, consultar qué contenidos son accesibles para un usuario según los conceptos que ya domina.
- **Ecosistema Python:** el driver oficial de Neo4j y bibliotecas como `py2neo` facilitan la integración con el backend y el pipeline de datos.
- **Community Edition:** permite ejecutar el prototipo sin licencias comerciales ni dependencia de proveedores cloud.
- **Modelo de grafo con propiedades:** permite almacenar atributos en nodos y relaciones. Por ejemplo, un nodo `Concepto` puede tener propiedades como `nombre`, `dificultad` y `categoría`; una relación `REQUIERE` puede incluir `peso_pedagogico` o `tipo_dependencia`.

2.6.3. Motor de IA y backend

Para el entrenamiento y servicio del modelo NeuMF se selecciona PyTorch. Esta biblioteca ofrece flexibilidad para definir arquitecturas personalizadas y facilita la experimentación con variantes del modelo, incluyendo configuraciones con variables contextuales.

Para la exposición del modelo mediante API REST se selecciona FastAPI. Esta tecnología

permite construir servicios web de forma eficiente, incorpora tipado mediante Pydantic y genera automáticamente documentación OpenAPI. Esto facilita la integración con el frontend y las pruebas del prototipo.

2.6.4. Integración KG-RecSys: estrategia de post-filtro

Respecto a la integración entre el grafo de conocimiento y el sistema de recomendación, se adopta como estrategia inicial un enfoque de post-filtro. En esta configuración, el modelo NeuMF genera un ranking de contenidos candidatos y el grafo de conocimiento descarta aquellos que violan prerequisites conceptuales.

Esta estrategia se prefiere inicialmente porque desacopla el entrenamiento del modelo neuronal de la evolución del grafo de conocimiento. De este modo, el catálogo de contenidos puede crecer o modificarse sin necesidad de reentrenar inmediatamente la red.

No obstante, como línea de comparación, se contempla evaluar una estrategia alternativa basada en el enriquecimiento de embeddings con información del grafo. Esto permitirá analizar si una integración más profunda entre el modelo de recomendación y el grafo mejora la calidad de las recomendaciones.

2.7. Conclusiones del estado del arte

La revisión de la literatura presentada en este capítulo permite extraer las siguientes conclusiones orientadoras para el desarrollo del trabajo:

1. **La alfabetización financiera de jóvenes españoles presenta una brecha relevante.** Existe una diferencia entre la capacidad de ahorro declarada y la gestión financiera efectiva, especialmente en el uso de instrumentos de planificación e inversión. Esta situación puede verse agravada por sesgos cognitivos como la sobreconfianza, el sesgo de presente o el efecto de anclaje.
2. **Los sistemas de recomendación tradicionales son insuficientes para el contexto educativo.** El filtrado colaborativo y los sistemas basados en contenido pueden ser útiles como líneas base, pero no modelan adecuadamente relaciones pedagógicas, prerequisites conceptuales ni progresión de aprendizaje.
3. **NeuMF representa una alternativa adecuada para la personalización.** Su arquitectura combina la capacidad de GMF para capturar patrones de interacción con la flexibilidad del MLP para modelar relaciones no lineales. Además, una variante

feature-aware permite incorporar información contextual del usuario.

4. **Los grafos de conocimiento aportan estructura pedagógica.** Los modelos de recomendación puros tienden a priorizar relevancia o probabilidad de interacción. En cambio, un grafo de conocimiento permite representar conceptos, prerrequisitos y rutas de aprendizaje.
5. **Existe un vacío científico identificado.** No se ha identificado en la literatura revisada un sistema que combine Neural Collaborative Filtering con Knowledge Graphs específicamente diseñado para la educación financiera de jóvenes profesionales, integrando simultáneamente personalización de contenido, restricciones pedagógicas y evaluación de maestría. Este vacío constituye la oportunidad de contribución del presente trabajo.

3. Objetivos y metodología de trabajo

3.1. Objetivos del trabajo

El objetivo general del presente trabajo es **desarrollar** un prototipo funcional de una plataforma software basada en inteligencia artificial que, mediante técnicas de aprendizaje automático y sistemas de recomendación, permita personalizar contenidos de educación financiera en función del perfil y del contexto económico del usuario, con especial enfoque en jóvenes profesionales.

Como objetivos específicos se plantean:

- Diseñar un modelo de perfilado financiero mediante la recopilación, procesamiento y análisis de datos económicos, demográficos y comportamentales del usuario.
- Seleccionar modelos de aprendizaje automático, optimizar sus hiperparámetros y evaluar su desempeño en tareas de segmentación y clasificación de perfiles financieros.
- Desarrollar e implementar un prototipo web basado en inteligencia artificial que integre el modelo de perfilado financiero y un sistema de recomendación de contenidos educativos personalizados, con el fin de validar su funcionamiento en un entorno simulado o real.

El impacto esperado del trabajo es doble. Desde el punto de vista académico, permitirá la aplicación práctica de conocimientos en aprendizaje automático, sistemas de recomendación y desarrollo de software. Desde una perspectiva social, la personalización de la educación financiera en jóvenes profesionales contribuye a reducir las barreras de acceso al conocimiento económico, favoreciendo una formación más equitativa y adaptada a las necesidades individuales. Asimismo, este enfoque se alinea con los Objetivos de Desarrollo Sostenible, en particular con el ODS 4 (Educación de calidad) y el ODS 10 (Reducción de las desigualdades).

4. Identificación de Requisitos

4.1. Introducción

En este capítulo se identifican los requisitos principales del prototipo. El objetivo es definir qué debe hacer el sistema, qué datos necesita y qué restricciones debe cumplir para recomendar contenidos educativos de educación financiera de forma personalizada.

El sistema está dirigido a jóvenes residentes en España, entre 18 y 34 años, con interés en mejorar su alfabetización financiera. La plataforma no pretende ofrecer asesoramiento financiero, sino recomendar contenidos educativos adecuados al nivel y progreso del usuario.

4.2. Identificación del problema

La educación financiera es importante para tomar decisiones económicas responsables. Sin embargo, muchos recursos disponibles ofrecen contenidos genéricos que no consideran el nivel de conocimiento, el contexto económico ni las necesidades concretas de cada usuario.

En este trabajo, el problema se centra en la falta de personalización en los contenidos de educación financiera. Un mismo contenido no es igual de útil para un usuario principiante que para otro con conocimientos previos. Por ello, se propone un sistema capaz de recomendar contenidos según el perfil del usuario y su progreso de aprendizaje.

Además, en educación financiera es necesario evitar recomendaciones demasiado avanzadas. Por ejemplo, no sería adecuado recomendar contenidos sobre inversión si el usuario no comprende antes conceptos básicos como ahorro, interés, riesgo o diversificación.

4.3. Usuario objetivo

El usuario objetivo del sistema son jóvenes residentes en España, entre 18 y 34 años. Este grupo puede incluir estudiantes, jóvenes profesionales o personas que empiezan a gestionar ingresos, ahorro, deuda o inversión básica.

Tabla 4.1: Perfil del usuario objetivo

Aspecto	Descripción
Edad	18 a 34 años.
Ubicación	España.
Nivel financiero	Básico o intermedio.
Necesidad principal	Aprender finanzas personales de forma progresiva.
Uso esperado	Plataforma web de recomendación educativa.

4.4. Contexto de uso

El sistema se utilizará como una aplicación web. El usuario completará un cuestionario inicial para definir su perfil financiero y, a partir de esa información, recibirá recomendaciones de contenidos educativos.

El uso esperado será progresivo. El usuario podrá empezar con temas básicos, como presupuesto, ahorro o deuda, y avanzar hacia temas más complejos, como inversión, diversificación o planificación financiera.

4.5. Requisitos funcionales

Los requisitos funcionales principales son:

- El sistema debe permitir identificar al usuario.
- El sistema debe recoger información inicial mediante un cuestionario.
- El sistema debe estimar el nivel financiero inicial del usuario.
- El sistema debe almacenar contenidos educativos clasificados por tema y dificultad.
- El sistema debe generar recomendaciones personalizadas.
- El sistema debe evitar recomendar contenidos cuyos prerrequisitos no estén cubiertos.
- El sistema debe registrar el progreso del usuario.
- El sistema debe actualizar las recomendaciones según la evolución del usuario.
- El sistema debe mostrar una explicación breve de cada recomendación.

4.6. Requisitos no funcionales

Los requisitos no funcionales principales son:

- La aplicación debe poder utilizarse desde un navegador web.
- La interfaz debe ser clara y sencilla.
- El sistema debe responder en tiempos aceptables.
- Los datos personales del usuario deben protegerse adecuadamente.
- El sistema debe ser modular para permitir mejoras futuras.
- El catálogo de contenidos debe poder ampliarse sin modificar todo el sistema.

4.7. Requisitos de datos

El sistema necesita distintos tipos de datos para funcionar correctamente:

- **Datos del usuario:** edad, nivel educativo, situación laboral, conocimientos financieros iniciales, hábitos de ahorro y experiencia previa.
- **Datos de contenidos:** título, descripción, tema, nivel de dificultad, duración, formato y fuente.
- **Datos conceptuales:** conceptos financieros y relaciones de prerrequisito.
- **Datos de interacción:** contenidos vistos, completados, valoraciones y resultados de cuestionarios.

Estos datos permiten relacionar el perfil del usuario con los contenidos disponibles y con su progreso de aprendizaje.

4.8. Requisitos pedagógicos

Dado que el objetivo del sistema es educativo, las recomendaciones deben seguir una progresión lógica. Por ello, se establecen los siguientes requisitos pedagógicos:

- Los contenidos deben organizarse por nivel de dificultad.
- Cada contenido debe indicar qué conceptos enseña.
- Cada contenido debe indicar qué conceptos requiere previamente.
- El sistema debe priorizar contenidos adecuados al nivel del usuario.
- El sistema debe evitar contenidos demasiado complejos para usuarios principiantes.
- Las recomendaciones deben favorecer el aprendizaje, no solo la interacción.

4.9. Requisitos de seguridad financiera

El sistema debe limitarse a la educación financiera. Por tanto, se definen las siguientes restricciones:

- El sistema no debe recomendar productos financieros concretos.
- El sistema no debe dar asesoramiento financiero personalizado.
- Los contenidos de inversión solo deben recomendarse si el usuario domina conceptos previos.
- Las fuentes de contenido deben ser confiables, preferentemente institucionales.
- El sistema debe diferenciar claramente entre educación financiera y consejo financiero.

4.10. Requisitos del sistema de recomendación

El recomendador debe generar una lista de contenidos adecuados para cada usuario. Para ello, debe considerar:

- el perfil inicial del usuario;
- su nivel de conocimiento financiero;
- sus intereses u objetivos de aprendizaje;
- los contenidos disponibles;
- los prerrequisitos conceptuales de cada contenido;
- el progreso registrado en la plataforma.

El ranking generado por el modelo de recomendación deberá filtrarse mediante reglas pedagógicas. De esta forma, el sistema evitará mostrar contenidos que el usuario aún no está preparado para comprender.

4.11. Requisitos del grafo de conocimiento

El grafo de conocimiento representará los conceptos financieros y sus relaciones. Su función principal será comprobar si un usuario cumple los prerrequisitos necesarios antes de recibir una recomendación.

El grafo deberá permitir representar:

- conceptos financieros;

- contenidos educativos;
- relaciones de prerrequisito entre conceptos;
- conceptos enseñados por cada contenido;
- conceptos ya dominados por el usuario.

Por ejemplo, antes de recomendar un contenido sobre fondos indexados, el sistema debería comprobar si el usuario entiende conceptos como riesgo, diversificación, inflación e interés compuesto.

4.12. Conclusiones del capítulo

En este capítulo se definieron los requisitos principales del prototipo. Estos requisitos muestran que el sistema no debe limitarse a recomendar contenidos relevantes, sino que debe hacerlo de forma adecuada al nivel del usuario, respetando una progresión pedagógica y evitando recomendaciones financieras inadecuadas.

Los requisitos identificados servirán como base para el diseño de la arquitectura, la selección tecnológica y la implementación del prototipo.

5. Descripción de la herramienta software desarrollada

5.1. Descripción

La herramienta desarrollada consiste en un prototipo web para la recomendación personalizada de contenidos educativos en educación financiera. El sistema permite que el usuario introduzca información básica sobre su perfil, reciba recomendaciones adaptadas a su nivel y consulte contenidos organizados según una progresión pedagógica.

El prototipo se plantea como una prueba de concepto funcional. Su objetivo no es desplegar una plataforma productiva, sino demostrar la viabilidad técnica del enfoque propuesto mediante la integración de un modelo de recomendación, una API y una aplicación web.

5.1.1. Objetivo de la herramienta

El objetivo principal de la herramienta es recomendar contenidos educativos personalizados a jóvenes residentes en España, considerando su nivel de conocimiento financiero, sus intereses y los prerrequisitos conceptuales de cada contenido.

La aplicación no recomienda productos financieros ni ofrece asesoramiento financiero personalizado. Su función se **limita** a organizar y recomendar recursos educativos de forma **progresiva**.

5.1.2. Proceso de desarrollo

El desarrollo del prototipo se organizó en fases incrementales. Cada fase permitió construir una parte concreta del sistema hasta obtener una versión funcional.

Tabla 5.1: Fases del proceso de desarrollo

Fase	Descripción
Fase 1	Definición de requisitos del sistema y del perfil de usuario objetivo.
Fase 2	Construcción del catálogo inicial de contenidos educativos.
Fase 3	Definición de conceptos financieros y relaciones de prerrequisito.
Fase 4	Implementación del backend y de la API de recomendación.
Fase 5	Desarrollo de la interfaz web del usuario.
Fase 6	Integración del sistema de recomendación con el grafo de conocimiento.
Fase 7	Pruebas funcionales del prototipo.

5.1.3. Arquitectura general

La arquitectura del sistema se compone de cuatro bloques principales: interfaz web, backend, motor de recomendación y grafo de conocimiento. La interfaz permite la interacción con el usuario; el backend coordina las peticiones; el modelo genera recomendaciones; y el grafo valida que los contenidos respeten los prerrequisitos pedagógicos.

Nota pendiente

Incluir diagrama de arquitectura general.

El flujo general del sistema es el siguiente:

1. El usuario accede a la aplicación web.
2. Completa un cuestionario inicial de perfilado.
3. El backend procesa los datos del usuario.
4. El modelo de recomendación genera una lista de contenidos candidatos.
5. El grafo de conocimiento filtra los contenidos que no cumplen los prerrequisitos.
6. La aplicación muestra las recomendaciones finales.

5.1.4. Componentes principales

El prototipo está formado por los siguientes componentes:

- **Frontend web:** permite completar el cuestionario inicial, visualizar recomendaciones y consultar contenidos.
- **Backend:** expone la API del sistema y coordina la comunicación entre los componentes.
- **Modelo de recomendación:** genera un ranking personalizado de contenidos educativos.
- **Grafo de conocimiento:** representa conceptos financieros, contenidos y relaciones de prerequisite.
- **Base de datos:** almacena usuarios, contenidos, interacciones y resultados de aprendizaje.

5.1.5. Tecnologías utilizadas

El prototipo utiliza un stack tecnológico orientado al desarrollo rápido de una aplicación demostrable. Se emplea Python para el procesamiento de datos, PyTorch para el modelo de recomendación, FastAPI para la integración mediante API, Neo4j para el grafo de conocimiento y React para la interfaz web.

Tabla 5.2: Tecnologías utilizadas en el prototipo

Tecnología	Uso en el sistema
Python	Procesamiento de datos y lógica principal.
PyTorch	Implementación del modelo de recomendación.
FastAPI	Desarrollo de la API de integración.
Neo4j	Representación del grafo de conocimiento financiero.
React	Desarrollo de la interfaz web del usuario.
Pandas / NumPy	Limpieza, transformación y análisis de datos.

5.1.6. Funcionamiento de la aplicación

Desde el punto de vista del usuario, el funcionamiento de la herramienta se organiza en cuatro pasos:

1. **Perfilado inicial:** el usuario responde un cuestionario sobre conocimientos financieros, hábitos e intereses.
2. **Generación de recomendaciones:** el sistema calcula contenidos adecuados para el perfil del usuario.
3. **Filtrado pedagógico:** el grafo elimina contenidos cuyos prerrequisitos no estén cubiertos.
4. **Visualización de resultados:** el usuario recibe una lista de contenidos recomendados y puede consultar su progreso.

Nota pendiente

Incluir diagrama flujo de interaccion, captura de las pantallas principales, link al repo

5.1.7. Pantallas principales

A continuación se presentan las pantallas principales del prototipo. Estas capturas permiten entender el funcionamiento general de la aplicación.

Pantalla de inicio

La pantalla de inicio presenta el objetivo de la plataforma y permite iniciar el proceso de perfilado.

Cuestionario inicial

El cuestionario inicial recopila información básica sobre el usuario, como nivel de conocimiento financiero, experiencia previa e intereses de aprendizaje.

Pantalla de recomendaciones

Esta pantalla muestra los contenidos educativos recomendados. Cada recomendación puede incluir el título, tema, dificultad y una breve explicación del motivo por el que fue seleccionada.

Pantalla de progreso

La pantalla de progreso permite visualizar los contenidos completados y el avance del usuario dentro del itinerario educativo.

5.1.8. Integración de los componentes

La integración del prototipo se realiza mediante una API que conecta la aplicación web con el backend y el modelo de recomendación. Esta API recibe los datos del usuario, solicita recomendaciones al modelo, consulta el grafo de conocimiento y devuelve al frontend una lista final de contenidos recomendados.

5.1.9. Resultado obtenido

5.1.10. Conclusión

6. Conclusiones y Trabajo Futuro

En la Ecuación (6.1)

$$M = \begin{pmatrix} m_{11} & m_{12} \\ m_{21} & m_{22} \end{pmatrix} \quad (6.1)$$

En la siguiente Tabla 6.1

1	2
22	11

Tabla 6.1: Tabla 1

En la siguiente Figura 6.1



Figura 6.1: Logo Unir

(Pimentel y Teixeira, 2016) (da S. Bessa, da Silva, Frederico, y Ricarte, 2023)

Referencias

- da S. Bessa, J., da Silva, J. V., Frederico, M. N., y Ricarte, G. C. (2023, sep). Sharp hessian estimates for fully nonlinear elliptic equations under relaxed convexity assumptions, oblique boundary conditions and applications. *Journal of Differential Equations*, 367, 451-493. Descargado de <https://doi.org/10.1016%2Fj.jde.2023.05.006> doi: 10.1016/j.jde.2023.05.006
- D'Ignazio, A., y Buratti, G. (2023). Improving the effectiveness of financial education programs: A targeting approach. *Journal of Consumer Affairs*. Descargado de <https://doi.org/10.1111/joca.12577> (También disponible como Bank of Italy Occasional Paper No. 765) doi: 10.1111/joca.12577
- Duan, C., Yang, J., Cui, Q., Zhang, W., Wan, X., y Zhang, M. (2025). Enhancing the recommendation of learning resources for learners via an advanced knowledge

- graph. *Applied Sciences*, 15(8), 4204. Descargado de <https://doi.org/10.3390/app15084204> doi: 10.3390/app15084204
- Gao, Y., Li, Y.-F., Lin, Y., Gao, H., y Khan, L. (2020). Deep learning on knowledge graph for recommender system: A survey. *arXiv preprint arXiv:2004.00387*.
- Guo, Q., Zhuang, F., Qin, C., Zhu, H., Xie, X., Xiong, H., y He, Q. (2020). A survey on knowledge graph-based recommender systems. *IEEE Transactions on Knowledge and Data Engineering*. doi: 10.1109/TKDE.2020.3028705
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., y Chua, T.-S. (2017a). Neural collaborative filtering. *Proceedings of the 26th International Conference on World Wide Web*, 173–182.
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., y Chua, T.-S. (2017b, apr). Neural collaborative filtering. En *Proceedings of the 26th international conference on world wide web (www '17)* (pp. 173–182). Perth, Australia: ACM. Descargado de <http://dx.doi.org/10.1145/3038912.3052569> doi: 10.1145/3038912.3052569
- Hospido, L., Machelett, M., Pidkuyko, M., y Villanueva, E. (2023, nov). *Encuesta de competencias financieras (ecf) 2021: Principales resultados y cambios desde 2016* (Inf. Téc.). Banco de España. Descargado de <https://doi.org/10.53479/34752> doi: 10.53479/34752
- Hua, Z., Yang, J., y Ji, W. (2025). Knowledge graph convolutional networks with user preferences for course recommendation. *Scientific Reports*, 15, 30256. Descargado de <https://doi.org/10.1038/s41598-025-14150-5> doi: 10.1038/s41598-025-14150-5
- Khanal, S. S., Prasad, P., Alsadoon, A., y Maag, A. (2020). A systematic review: machine learning based recommendation systems for e-learning. *Education and Information Technologies*, 25, 2635–2664. doi: 10.1007/s10639-019-10063-9
- Lusardi, A., y Mitchell, O. S. (2014). The economic importance of financial literacy: Theory and evidence. *Journal of Economic Literature*, 52(1), 5–44. Descargado de <https://doi.org/10.1257/jel.52.1.5> doi: 10.1257/jel.52.1.5
- Marín, R., y Notargiacomo, P. (2021). Multiagent intelligent tutoring system for financial literacy. *International Journal of Web-Based Learning and Teaching Technologies*, 17(7), 1–13. Descargado de <https://doi.org/10.4018/IJWLTT.288035> doi: 10.4018/IJWLTT.288035
- Organisation for Economic Co-operation and Development. (2023). *OECD/INFE 2023*

- International Survey of Adult Financial Literacy* (Inf. Téc.). Paris: OECD Publishing. Descargado de <https://www.oecd.org/finance/financial-education/oecd-infe-2023-international-survey-of-adult-financial-literacy.htm>
- Pimentel, E. A., y Teixeira, E. V. (2016). Sharp hessian integrability estimates for nonlinear elliptic equations: An asymptotic approach. *Journal de Mathématiques Pures et Appliquées*, 106(4), 744-767. Descargado de <https://www.sciencedirect.com/science/article/pii/S0021782416300101> doi: <https://doi.org/10.1016/j.matpur.2016.03.010>
- Verma, G., Sarkar, S., Pillai, D., Chen, H., McCrae, J. P., Perge, J. A., ... Buitelaar, P. (2023). *Empowering recommender systems using automatically generated knowledge graphs and reinforcement learning*. Descargado de <https://doi.org/10.48550/arXiv.2307.04996> doi: 10.48550/arXiv.2307.04996
- Zhang, S., Yao, L., Sun, A., y Tay, Y. (2019). Deep learning based recommender system: A survey and new perspectives. *ACM Computing Surveys*, 52(1), 1–38. doi: 10.1145/3285029
- Zhu, A. Y. F. (2024). Unlocking financial literacy with machine learning: A critical step to advance personal finance research and practice. *Technology in Society*, 81, 102797. Descargado de <https://doi.org/10.1016/j.techsoc.2024.102797> doi: 10.1016/j.techsoc.2024.102797

A. Apendices